

数据挖掘课程项目 - 最终报告模板

请按本模板填写并导出为 PDF 提交。

0. 项目基本信息

- 项目名称：[请填写最终项目名称]
- 项目方向（对照 **Proposal**）：[如：知识增强问答 / 复杂 Data-Centric 改进 / 过程挖掘 / 因果增量策略优化 / Agentic 数据分析评估]
- 代码仓库链接：[请填写公开仓库 URL]
- 小组成员与分工：

姓名	学号	开题角 色	最终实际贡献（精确到模块/ 功能）	代码贡献 (commit 数)
张三（组长）	2026xxxx	算法开发	核心图检索模块设计与实现、 消融实验全程	58
李四	2026xxxx	数据工程	完整数据审计与预处理管道、 知识图谱构建	41
王五	2026xxxx	评测与 实验	评测框架、对比实验、可视化 图表、报告撰写	35

1. 摘要 (Abstract)

200–300 字。需涵盖：① 问题背景与核心挑战；② 方法核心思路（1–2 句）；③ 关键量化结果（必须有数字）；④ 主要局限性。不得只写定性描述。

[例：本项目针对医学文献多跳推理问答场景中大语言模型的幻觉问题，提出了一种基于知识图谱增强的 GraphRAG 系统。核心挑战在于原始文献存在 15.3% 的实体标注噪音，以及跨文档关系在纯向量检索下的严重丢失。我们构建了端到端数据预处理管道，结合 Snorkel 多标签融合完成噪音治理，并在此基础上构建 38,000 节点规模知识图谱，通过层次化社群检索替代平铺式向量检索。在 100 个人工标注多跳问答 Benchmark 上，所提方法在答案忠实度 (Faithfulness) 上达 0.84，相比基线向量 RAG (0.61) 提升 37.7%，检索召回率 (Recall@5) 提升 16.2 个百分点。局限性在于推理延迟从 1.2s 升至 3.5s，在时延敏感场景尚不可用。]

2. 问题定义与动机

2.1 研究背景与核心挑战

说明真实场景的业务/科学价值 (3–5 句)，并量化核心痛点。避免空洞的背景陈述。

- 核心问题：**[例：医生使用大模型辅助查询病例文献时，模型的幻觉率（胡编文献内容）高达 38%，导致无法直接用于临床参考]
- 现有方案的不足：**[例：现有向量 RAG 在需要跨文档推理的问题上召回率仅 72.4%，知识边界不清晰]
- 本项目目标：**[例：在保持问答相关性的前提下，将幻觉率降至 10% 以下，并能追溯答案来源]

2.2 任务形式化

请用清晰的数学/逻辑语言定义输入和输出。

- **输入：**[例：医学文献集合 $\mathcal{D} = \{d_1, \dots, d_n\}$ 与自然语言问题 q]
- **输出：**[例：带证据来源标注的答案 a ，以及支撑答案的文献片段集合 $\mathcal{E} \subseteq \mathcal{D}$]
- **成功标准：**[例： $\text{Faithfulness}(a, \mathcal{E}) \geq 0.80$, $\text{Recall}@5 \geq 85\%$]

2.3 与开题报告的偏差说明

如最终研究问题或范围与开题报告有偏差，必须在此说明原因（限 3–5 句）。

3. 数据来源与全量审计报告

3.1 数据集说明

数据集	来源 / 获取方式	规模	用途
[如：PubMed 摘要子集]	[Kaggle / HuggingFace datasets]	[23,000 篇摘要, 2.1GB]	[构建知识图谱 + 训练集]
[如：自建问答 Benchmark]	[人工标注, 50人时]	[100 个多跳问答对]	[模型评测]

3.2 数据质量全量审计


请至少列出 3 条经代码实测的数据问题（包含开题预测与实际发现的差异分析）。


#	数据问题	量化规模	发现方式（精确到脚本/函数）	解决方案	处理前 → 处理后效果
1	噪声标签	15.3% 样本标签冲突	<code>src/audit.py::label_conflict_check()</code>	Snorkel LabelModel 多源融合	冲突率 15.3% → 2.1%, Precision +4.7%
2	实体长尾分布	63% 实体出现 < 3 次	<code>notebooks/eda.ipynb</code> Cell 12	频次过滤 + 语义消歧	图谱节点 12万 → 3.8万, 查询跳数 -1.2
3	[请填写真实发现]				

开题预测 vs 实际差异： [例：开题预测存在类别不平衡问题，实际发现更严重的是实体消歧错误（同一实体 3 种写法），此前未预计到。]

3.3 数据处理管道

展示从原始数据到模型输入的完整流水线，每个节点标注对应脚本/函数名。






4. 方法设计

4.1 系统架构

使用 Mermaid 或图示展示系统整体架构，各模块对应代码文件。



4.2 核心创新点说明

描述相比基线方法的 1-2 个核心改进，说明其设计动机（"为什么这样设计"）。

- **创新点 1:** [例：层次化社群检索——基于图的 Leiden 社区算法将图谱划分为语义社群，并为每个社群生成摘要索引，解决了长链推理中向量检索无法覆盖跨文档关系的问题]
- **创新点 2:** [例：实体感知的查询扩展——从问题中提取实体锚点并在 KG 上做 k 跳邻居扩展，提升稀疏查询场景下的召回]

4.3 技术栈

模块	工具 / 框架	版本
数据处理	Pandas, Snorkel	2.1.0, 0.9.8
图谱构建	spaCy, NetworkX	3.7.2, 3.3
图存储	Neo4j / NetworkX（本地）	5.18
检索与嵌入	sentence-transformers, FAISS	3.0, 1.8
生成模型	Qwen3-8B（本地部署）	—
评测	RAGAS	0.1.21

5. 实验设计与结果

5.1 评测数据集与指标

- **测试集构建**: [例: 人工标注 100 个多跳推理问答对, 其中 60 个来自训练集文献领域外的新文献 (Domain-shift 场景), 40 个来自训练领域内。所有标注由 2 人独立完成, 一致性 $\kappa=0.82$ 。]
- **数据切分方式**: [必须说明切分是否按时间/用户/领域进行, 不可随机切分场景需声明原因]
- **核心评测指标**:

指标	含义	评估工具
Faithfulness	答案内容可被检索片段覆盖的比例 (防幻觉核心指标)	RAGAS
Answer Relevance	答案与问题的相关程度	RAGAS
Recall@5	正确答案所需证据是否出现在 Top-5 检索结果中	自研 src/evaluate.py
Context Precision	检索出的片段中真正有用的比例	RAGAS

5.2 基线对比实验

方法	Faithfulness	Answer Relevance	Recall@5	Context Precision	推理耗时
Baseline	0.61	0.74	72.4%	0.68	1.2s
Ours	0.84 (+0.23)	0.81 (+0.07)	88.6% (+16.2%)	0.79 (+0.11)	3.5s

5.3 消融实验

消融设置	Faithfulness	Recall@5	说明
完整系统（Full）	0.84	88.6%	—
w/o 社群摘要索引（仅图邻居检索）	0.76	84.1%	验证社群摘要对全局推理的贡献
w/o 实体锚点扩展（仅向量检索）	0.68	77.3%	验证结构化检索路径的贡献
w/o 数据噪声治理（Snorkel）	0.71	81.5%	验证数据质量改进对最终指标的影响

5.4 一键复现命令

```
# 1. 环境安装
pip install -r requirements.txt

# 2. 数据准备（或下载脚本）
python data/download.py --output data/raw/

# 3. 数据预处理 & 图谱构建
python src/preprocess.py --input data/raw/ --output data/processed/
python src/graph_build.py --input data/processed/ --output data/graph/

# 4. 运行评测（复现论文表格主要结果）
python src/evaluate.py --config configs/eval_full.yaml --output results/
```

5.5 随机种子与可复现性说明

- **随机种子**：所有实验固定 `seed=42`，在 `src/utils.py::set_seed()` 中统一设置
- **依赖版本锁定**：`requirements.txt` 已锁定所有包版本（`pip freeze` 生成）
- **已知不可复现因素**：[例：RAGAS 评分调用 OpenAI API 存在随机性，可使用本地 Qwen3-8B 替代（见 `configs/eval_local.yaml`）]，两者结果相差 ≤ 0.02

6. 误差分析与失败复盘

6.1 失败案例分析

#	失败类型	输入 (Query 片段)	系统输出	正确答案	根因分析	改进方向
1	知识稀疏	"糖尿病与高血压共病机制?"	遗漏了胰岛素抗性路径	包含胰岛素抗性 + RAS 轴	相关实体被频次过滤删除	放宽过滤阈值，引入语义相似度补充稀疏实体
2	多跳失效	"药物 A 通过靶点 B 影响通路 C?"	仅返回 A→B 关系，缺 B→C	A→B→C 完整路径	Leiden 社群划分将 B、C 分入不同社群，摘要未覆盖	调整社群粒度参数，或引入跨社群边界检索
3	幻觉生成	[请填写真实失败案例]				

6.2 分组误差分析

报告至少 1 种分组指标（如：领域内 vs 领域外、短问题 vs 多跳长问题），并分析差异原因。

问题类型	样本数	Faithfulness	Recall@5	差异原因分析
领域内问题（训练集领域）	40	0.91	93.2%	图谱实体覆盖充分
领域外问题（跨领域迁移）	60	0.79	85.7%	图谱未覆盖新领域实体，检索产生跨域噪音
单跳问题	35	0.90	95.4%	—
多跳推理问题	65	0.80	84.6%	多跳路径在图中不连续

6.3 高阶能力自评

请勾选本项目覆盖的高阶维度（至少应覆盖 **1 项**，覆盖 ≥ 2 项可申请附加分）：

- ☐ 数据质量闭环（系统的噪声治理/弱监督/漂移处理，且量化了改进增益）
- ☐ 过程挖掘（从日志反推业务流程，定位真实瓶颈）
- ☐ 图或知识图谱结构化挖掘（非仅调用 API，含图构建 + 分析实验）
- ☐ 因果分析（含 PSM/IPW/Uplift Model，非仅相关性分析）
- ☐ LLM/Agent 协同数据科学（含失败案例与安全边界分析，非仅调用 ChatGPT）

7. 代码仓库审计

- 最终 commit 统计：
 - 总 commit 数：[如 134 次]，各成员贡献：[张三 58 / 李四 41 / 王五 35]
 - 最近一次有效 commit 时间：[如：2026-06-14（非格式化/readme 类空 commit）]
- 仓库最终目录结构（运行 `tree -L 2` 粘贴实际输出，不可使用样例替代）：

请粘贴 `tree -L 2` 的真实输出，并在右侧注释各模块功能

└─ README.md	# 环境配置 + 一键复现命令 (含每步预期输出)
└─ requirements.txt	# pip freeze 锁定版本
└─ configs/	
└─ eval_full.yaml	# 完整评测配置
└─ eval_local.yaml	# 本地离线评测配置
└─ data/	
└─ download.py	# 数据下载脚本
└─ processed/	# 预处理后的中间数据
└─ src/	
└─ preprocess.py	# 数据清洗与 Snorkel 标签融合
└─ graph_build.py	# 知识图谱构建
└─ indexing.py	# 社群摘要索引
└─ retrieval.py	# 双路检索逻辑
└─ pipeline.py	# 端到端问答主流程
└─ evaluate.py	# 评测框架与指标计算
└─ notebooks/	
└─ eda.ipynb	# 探索性分析与数据审计可视化
└─ results/	# 实验输出 (由 evaluate.py 生成)

8. 结论与局限性

8.1 主要贡献总结

(3-5 个条目，每条须有量化数据支撑)

1. **[如：构建了含 38,000 节点的医学知识图谱]**，覆盖了[X]种疾病领域的实体关系
2. **[如：Faithfulness 从 0.61 提升至 0.84 (+37.7%)]**，通过层次化社群检索有效缓解了跨文档推理幻觉
3. **[如：消融实验证明]**，数据噪声治理 (Snorkel) 对最终 Faithfulness 贡献约 0.08，不可忽略

8.2 局限性与未来工作

局限性	影响	未来可行方向
推理延迟从 1.2s 升至 3.5s	不适用于实时问答场景	图索引并行化 + 查询缓存
跨领域泛化能力下降 10%	新领域需重新构建图谱	开放域通用图谱或增量扩展机制
测试集规模仅 100 条	评估结论的统计稳定性有限	扩大标注规模或使用开源 Benchmark

9. AI 工具辅助使用声明

按照课程规范，请如实填写。若完全未使用 AI 工具，在表格中注明"未使用"即可。

使用场景	AI 工具名称	具体辅助环节（精确到文件/功能）	团队审查与纠错说明
代码编写	[如：Copilot]	[如：辅助编写 <code>src/retrieval.py</code> 中双路检索逻辑]	[如：逐行 Review，修复了检索路径合并的逻辑错误]
报告撰写	[如：ChatGPT]	[如：润色摘要与结论的英文描述]	[如：组长核对事实准确性，删除夸大表述]
算法思路	[如：Claude]	[如：咨询 Leiden 算法参数设定的参考文献]	[如：独立实现，仅参考方向，非直接复制代码]
[其他/未使用]			