

数据挖掘课程项目 - 中期进展报告

0. 项目基本信息

- 项目名称：纽约市出租车行程数据挖掘：基于 Data-Centric 方法的费用预测与运营规律分析
- 项目仓库：<https://github.com/C-CH621/datamining-taxi-2026-ChiikaDD>
- 当前阶段：中期阶段，已完成数据审计、处理后数据集构造、baseline 模型拆分与新版数据适配，并完成四类 baseline 的 RMSE 对比。

0.1 小组成员与分工

成员	学号	当前主要分工	中期已完成工作
徐文彬	1120221397	数据审计、模型评估、对比分析	原始数据审计、指标设计、实验结果整理
赵会洋	1120221594	baseline 建模、结果评估、报告整理	四类 baseline 拆分、适配新版数据、RMSE 评估与文档补充
崔琛浩	1120221572	数据清洗、治理管道、特征工程	处理后数据构造、治理规则实现、数据质量标记

0.2 仓库状态

- 当前仓库已有 36 次 commit（命令：`git log --oneline | wc -l`）。
- 当前本地仓库为 main 分支；远端为 origin/main。
- `git shortlog -sn --all` 显示活跃提交身份共 5 个：CC、m0_74090594、WenbinXu_WSL、崔琛浩、RoxyXu。其中包含成员不同设备或账号别名。
- 主要目录结构如下：

```
1 | .
2 | └─ README.md                # 项目说明与运行入口
3 | └─ requirements.txt         # Python 依赖
4 | └─ data/
5 |   └─ raw/                  # 原始 TLC/FHVVH 数据
6 |     └─ processed/
7 |       └─ fhvhv_tripdata_2026-03_prediction_format/ # train/test/sample_submission
8 |         └─ governed_data_description.md
9 | └─ document/
10 |   └─ midterm/              # 开题报告、中期报告与模板
11 | └─ results/
12 |   └─ baseline/            # 四类 baseline 预测结果
13 |     └─ core_model/        # 进阶模型预测结果与指标
```

```

14 |— src/
15 |   |— baseline/           # 新版 baseline 代码与评估脚本
16 |   |— baseline_kaggle/   # 早期 Kaggle baseline 拆分版本
17 |   |— core_model.py      # 进阶模型入口
18 |   |— data_audit.py      # 数据审计逻辑
19 |   |— governance_v2.py   # 数据治理与诊断逻辑
20 |   |— preprocess.py      # 预处理管道入口
21 |   |— evaluate.py        # 评估工具占位/后续扩展
22 |— tests/                 # 测试目录

```

2. 数据工程与审计落地

2.1 原始数据审计反馈

数据文件: `data/raw/fhvhv_tripdata_2026-03.csv`

审计脚本: `src/preprocess.py`、`src/data_audit.py`、`src/governance_v2.py`

处理后建模数据: `data/processed/fhvhv_tripdata_2026-03_prediction_format/train.csv`、`test.csv`、`sample_submission.csv`

量化口径说明: 原始大文件不纳入 Git; 下表数字来自 `src/data_audit.py`、`src/governance_v2.py` 生成的审计与治理诊断结果, 以及当前可复现的处理后训练文件抽样复核。


数据问题	量化规模	解决方案 (精确到文件/函数)	处理后效果
缺失机制 (<code>originating_base_num</code>)	缺失率 27.5933%; 缺失预测 AUC=0.9993; 目标分布 KS-p=2.10e-08 (<code>MAR_likely</code>)	缺失机制诊断见 <code>src/governance_v2.py::diagnose_missing_mechanism</code> ; 治理中对高影响特征采用分组中位数+全局中位数补全, 见 <code>src/governance_v2.py::govern_dataset_for_model</code>	避免直接删去高影响缺失样本; B 策略样本损失率 0%, A 策略样本损失率 0.0087%
标签噪音 (规则冲突 + 弱监督不一致)	规则冲突率 3.0263%; 弱监督不一致率 17.1704%; 疑似噪音率 18.5087%	规则冲突与弱监督一致性诊断见 <code>src/governance_v2.py::diagnose_label_noise</code> ; 抽检样本见 <code>results/manual_audit_sample_noise.csv</code>	通过“标记+修复+缩尾”降低噪音影响; A/B 中 MAE 4.7044 -> 4.6993, RMSE 8.6570 -> 8.6181
时间漂移 (周内漂移)	Week1 vs Week4: <code>trip_miles</code> PSI=0.00148、KS-p=0.0066; <code>base_passenger_fare</code> PSI=0.00024、KS-p=0.00167	漂移诊断见 <code>src/governance_v2.py::diagnose_time_drift</code> (PSI + KS + Wasserstein)	当前为“弱漂移”, 不触发重训, 仅持续监控; 避免过度治理导致分布失真

数据问题	量化规模	解决方案（精确到文件/函数）	处理后效果
子群体差异（平台/时段/区域）	平台质量问题率： HV0003=0.1080%、 HV0005=0.0599%；高峰/低峰质量问题率存在差异（0.0742% vs 0.1066%）	分群诊断见 src/governance_v2.py::subgroup_diagnostics	训练评估阶段纳入分群稳定性与公平性指标（子群体误差标准差、公平性差距）
开题预测未发生项	on_scene_datetime 缺失率 0； dispatching_base_num 长尾（freq<3）占比 0	审计统计见 src/data_audit.py::audit_raw_data 与 results/raw_audit_2026_03.json	本批次 FHVHV 2026-03 数据结构较规整，缺失与长尾风险低于开题预期

审计结果如图：

```
{
  "total_rows": 22058358,
  "metrics": {
    "on_scene_missing_rate": 0.0,
    "duration_inconsistent_rate": 0.0004589190183602968,
    "speed_outlier_rate": 0.00018029447160119533,
    "negative_base_fare_rate": 0.0002570000903965744,
    "negative_driver_pay_rate": 4.080086106137184e-07,
    "dispatching_base_long_tail_ratio_freq_lt3": 0.0,
    "pickup_hour_psi_firsthalf_vs_secondhalf": 0.00114794476945407
  },
  "counts": {
    "on_scene_missing": 0,
    "duration_inconsistent": 10123,
    "speed_outlier": 3977,
    "negative_base_fare": 5669,
    "negative_driver_pay": 9,
    "dispatching_base_total_entities": 2,
    "dispatching_base_entities_freq_lt3": 0
  }
}
```

2.2 数据流与预处理管道



2.3 治理操作明细（补充说明）

本项目在治理过程中执行了以下可复现步骤：

- (1) 字段标准化
- 时间字段统一解析为 `datetime`：`request_datetime`、`on_scene_datetime`、`pickup_datetime`、`dropoff_datetime`。
 - 数值字段统一转为 `numeric`，非法值转为 `NaN`，避免后续统计和建模报错。
- (2) 缺失机制诊断与处理
- 对缺失字段进行机制判定（MCAR/MAR/MNAR 倾向），对应函数：`src/governance_v2.py::diagnose_missing_mechanism`。
 - 对高影响特征不做粗暴删行，采用“分组中位数（`dispatching_base_num + pickup_hour`）→ 全局中位数”的两级补全策略，见 `src/governance_v2.py::govern_dataset_for_model`。
 - 对低影响且极低占比缺失，在 A 策略中允许删除作为对照。
- (3) 语义约束治理

- 对业务上不应为负的字段（如 `base_passenger_fare`、`driver_pay`、`trip_miles`、`trip_time`）执行：
 - 负值置空（不直接删行）；
 - 同时写入标记字段（如 `flag_fare_negative` 等）保留审计痕迹。

(4) 跨字段一致性校验

- 构造 `duration_seconds = dropoff_datetime - pickup_datetime`。
- 生成 `flag_duration_inconsistent`：当 `|duration_seconds - trip_time| > 300` 秒。
- 构造 `speed_mph = trip_miles / (trip_time/3600)`，并生成 `flag_speed_outlier`（`speed_mph < 1` 或 `> 80`）。

(5) 异常值稳健化（非删除）

- 对 `trip_miles`、`trip_time`、`driver_pay`、`tips` 生成缩尾列：`*_capped`。
- 使用约 `0.1% ~ 99.9%` 分位缩尾，降低极端值杠杆效应，同时保留原始字段用于追溯。

(6) 子群体差异审计

- 按平台（`hvfhs_license_num`）、时段（高峰/低峰）、区域桶进行分层统计。
- 输出各子群体质量问题率与目标均值偏差，函数：`src/governance_v2.py::subgroup_diagnostics`。
- 目的：避免某一群体被过度清洗或误差显著偏高。

2.4 对照实验设计与结果（A/B）

实验设计

- 策略 A：`A_delete`（只删异常/缺失）
- 策略 B：`B_govern`（标记 + 修复 + 缩尾）
- 固定变量：同切分、同模型（`HistGradientBoostingRegressor`）、同特征、同随机种子
- 实现位置：`src/governance_v2.py::run_experiment`

实验结果

策略	RMSE	MAE	子群体误差标准差	公平性差距	样本损失率
A_delete	8.6570	4.7044	0.7185	1.4369	0.0087%
B_govern	8.6181	4.6993	0.7139	1.4279	0.0000%

- 显著性检验（配对置换）：`p-value= 0.1417`（当前样本条件下统计显著性有限，但方向一致）
- 误差差值（A-B，MAE 方向）：`+0.00515`（正值表示 B 更优）

实验结果证明

```
name,rmse,mae,subgroup_std,fairness_gap,sample_loss_rate
A_delete,8.657042598451921,4.704417071823934,0.7184680622468056,
1.4369361244936112,8.666666666667933e-05
B_govern,8.618136647891331,4.699270810870277,0.7139332494713919,
1.4278664989427838,0.0
```

2.5 落地产物与可复现命令

关键产物

- 审计报告: `results/raw_audit_2026_03.json`
- 诊断汇总: `results/governance_v2_diagnosis.json`
- 实验表: `results/governance_v2_experiment_table.csv`
- 治理后全量数据: `data/processed/fhvhv_tripdata_2026-03_governed_v2_full.parquet`
- 治理后 CSV: `data/processed/fhvhv_tripdata_2026-03_governed_v2_full.csv`

可复现命令

```
1 # 仅审计
2 python -m src.preprocess audit --input data/raw/fhvhv_tripdata_2026-03.csv --output
  results/raw_audit_2026_03.json
3
4 # 审计 + 治理 + 诊断 + A/B实验 (全流程)
5 python -m src.preprocess pipeline --input data/raw/fhvhv_tripdata_2026-03.csv --output
  results/raw_audit_2026_03.json
```

3. 基线模型与核心算法实现

3.1. 基线模型运行情况说明

所选基线方法:

中期阶段已实现并运行 4 类费用预测 baseline:

1. Simple Linear Model: 简单线性模型, 作为最低复杂度的可解释性基线。
2. Random Forest: 随机森林回归模型, 用于捕捉非线性特征交互。
3. LightGBM: 梯度提升树模型, 作为当前表现最好的表格数据 baseline。
4. XGBoost: 梯度提升树模型, 用于与 LightGBM 和 Random Forest 进行横向对比。

运行环境:

- Python 3.13
- pandas / NumPy / scikit-learn

- LightGBM
- XGBoost
- Windows PowerShell 本地环境

一键复现命令：

```
1 python src/baseline/simple_linear_model.py --output
  results/baseline/submission_simple_linear_model.csv
2 python src/baseline/LightGBM_model.py --output results/baseline/submission_LightGBM.csv
3 python src/baseline/XGBoost_model.py --output results/baseline/submission_XGBoost.csv
4 python src/baseline/Random_Forest.py --nrows 200000 --n-estimators 30 --output
  results/baseline/submission_Random_Forest.csv
5 python src/baseline/evaluate_rmse.py --truth data/processed/sample_submission.csv --results-dir
  results/baseline
```

关键输出片段：

```
PS D:\主要文件\论文与作业\大4下\数据挖掘\课程项目\datamining-taxi-2026-ChiikaDD> python src\baseline\evaluate_rmse.py --truth data\processed\samp
le_submission.csv --results-dir results\baseline
rank    model                file      rows  evaluated_rows  skipped_rows  rmse
-----
1      LightGBM             submission_LightGBM.csv 10000      9996           4 2.025860
2      Random Forest        submission_Random_Forest.csv 10000      9996           4 2.129185
3      XGBoost               submission_XGBoost.csv 10000      9996           4 3.569263
4      Simple Linear Model  submission_simple_linear_model.csv 10000      9996           4 7.435211
PS D:\主要文件\论文与作业\大4下\数据挖掘\课程项目\datamining-taxi-2026-ChiikaDD>
```

代码结构：

文件	模型/功能	说明
src/baseline/model_utils.py	公共工具	读取数据、清洗训练集、构造时间特征、编码类别特征、输出 submission
src/baseline/simple_linear_model.py	Simple Linear Model	使用 NumPy 最小二乘法拟合
src/baseline/Random_Forest.py	Random Forest	使用 sklearn.ensemble.RandomForestRegressor
src/baseline/LightGBM_model.py	LightGBM	使用 lightgbm 训练 GBDT 回归模型
src/baseline/XGBoost_model.py	XGBoost	使用 xgboost 训练梯度提升树
src/baseline/evaluate_rmse.py	评估脚本	与 data/processed/sample_submission.csv 对齐计算 RMSE

输入输出适配：

- 输入： data/processed/train.csv 、 data/processed/test.csv 、 data/processed/sample_submission.csv
- 预测目标： base_passenger_fare

- 输出列: `pickup_datetime, base_passenger_fare`
- 输出目录: `results/baseline/`


特征处理:

- 类别特征 (如 `hvfhs_license_num`、`dispatching_base_num`、`shared_request_flag` 等) 使用 one-hot 编码。
- 时间字段 (`request_datetime`、`on_scene_datetime`、`pickup_datetime`、`dropoff_datetime`) 不直接输入模型, 而是派生 `hour`、`dayofweek`、`day`、`month` 等特征。
- 额外构造 `request_to_pickup_seconds`、`request_to_scene_seconds`。
- 数值特征包括 `PULocationID`、`DOLocationID`、`trip_miles`、`trip_time`、`tolls`、`bcf`、`sales_tax`、`driver_pay`、`duration_seconds`、`speed_mph`、`*_capped` 和 `quality_issue_count` 等。
- 训练集中 `base_passenger_fare` 缺失或为负的样本会被过滤; 测试集不删行; 类别缺失填为 `"missing"`, 其他缺失最终填 `0`。

3.2. 核心进阶算法开发进度

当前项目的核心进阶方向为“数据治理 + 表格回归模型”的组合路线: 先通过数据审计和治理标记提升数据质量, 再比较不同模型在同一处理后数据上的表现。现阶段重点已完成 **baseline**, 可支撑后续核心模型和治理策略对照实验。

核心模块设计:



开发进度核查表：

模块	对应文件	状态	备注
数据预处理管道	src/preprocess.py、src/governance_v2.py	完成	已形成处理后data/processed输入
基线模型	src/baseline/*.py	完成	四类 baseline 均可运行并输出结果
核心进阶算法	src/core_model.py	进行中	后续将与 baseline 进行统一指标对比
评测框架	src/baseline/evaluate_rmse.py、src/evaluate.py	部分完成	baseline RMSE 已完成，通用评估入口待整合
单元测试 / 集成测试	tests/	进行中	后续补充训练与评估入口测试

4. 中期实验结果与阶段性分析

4.1. 评估指标与测试集构建

- 评估数据集规模：使用 `data/processed/test.csv` 生成 10000 行预测结果，并以 `data/processed/sample_submission.csv` 中的 `base_passenger_fare` 作为阶段性参考标签。
- 有效评估样本数：`sample_submission.csv` 中有 4 行 `base_passenger_fare` 缺失，因此评估脚本跳过缺失行，最终在 9996 行上计算 RMSE。
- 核心评估指标：RMSE（Root Mean Squared Error，均方根误差）。

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (1)$$

其中， $\hat{y}_i$ 为模型预测费用， y_i 为参考费用。RMSE 越低，说明预测误差越小。

评估脚本：

```
1 python src/baseline/evaluate_rmse.py --truth data/processed/fhvhv_tripdata_2026-03_prediction_format/sample_submission.csv --results-dir results/baseline
```

4.2 Baseline 与进阶模型定量对比结果

排名	模型	结果文件	训练设置	RMSE
1	Core Model	results/core_model/submission_core_model.csv	原生 lightgbm.train, nrows=1000000	1.989580
2	LightGBM baseline	results/baseline/submission_LightGBM.csv	nrows=1000000	2.025860
3	Random Forest baseline	results/baseline/submission_Random_Forest.csv	nrows=200000, n_estimators=30	2.129185
4	XGBoost baseline	results/baseline/submission_XGBoost.csv	nrows=1000000	3.569263
5	Simple Linear Model baseline	results/baseline/submission_simple_linear_model.csv	nrows=1000000	7.435211

说明：Core Model 的表内指标来自以下命令在 `nrows=1000000` 口径下的验证输出，与 baseline 对比口径一致：

```
1 /home/xuwenbin/miniconda3/bin/python -m src.core_model \
2 --input-dir data/processed/fhvhv_tripdata_2026-03_prediction_format \
3 --nrows 1000000
```

关键输出：

```
1 sample_submission_rmse: 1.9895804744488554
2 sample_submission_mae: 1.1027898822266968
3 sample_submission_r2: 0.9940273054324651
```

该结果相较旧版 Core Model 的 `sample_submission_rmse=2.135165` 有明显下降，也低于当前 LightGBM baseline 的 `2.025860`。需要注意的是，该结论限定在 `nrows=1000000` 训练口径下；若改用全量 `22,048,358` 行训练，sample submission 的 RMSE 可能因测试样本时间段分布不同而变化。

4.3 结果分析

- 1. Core Model 阶段性表现最好
Core Model 在 `nrows=1000000` 口径下取得最低 sample submission RMSE，说明对齐 baseline 清洗逻辑后，原生 `lightgbm.train` 与更细的参数设置能进一步提升结构化费用预测效果。
- 2. LightGBM baseline 仍是强基线
LightGBM baseline 的 RMSE 为 `2.025860`，与进阶模型差距不大，说明当前特征工程和清洗策略已经为 GBDT 类模型提供了较强输入。
- 3. Random Forest 接近 LightGBM
Random Forest 在只使用 20 万行训练数据、30 棵树的情况下仍取得第三名，说明特征工程对树模型较友好。但该模型训练成本较高，后续需要在样本量、树数量和运行时间之间做权衡。
- 4. XGBoost 结果弱于预期
当前 XGBoost RMSE 高于 LightGBM 和 Random Forest，可能与超参数设置较保守、boosting 轮数和学习率组合未充分调优有关。
- 5. 简单线性模型作为下界 baseline
简单线性模型误差最大，符合预期。当前费用预测受平台、区域、时段、里程、时长、附加费等多因素非线性影响，线性模型难以充分表达。

4.4 失败案例分析

以下失败案例按 `sample_submission.csv` 与预测文件的行序对齐计算，避免 `pickup_datetime` 重复导致交叉匹配。

#	行号	输入片段	模型输出	参考答案	失败原因	改进方向
1	7892	<code>pickup_datetime=2026-03-25 11:40:49</code>	LightGBM baseline: 119.2161	87.14	中高价行程被明显高估，可能与区域、时段和附加费用组合在训练集中对应样本较少有关	增加路线组合特征、按 <code>PULocationID-DOLocationID</code> 做分桶统计特征

#	行号	输入片段	模型输出	参考答案	失败原因	改进方向
2	5544	pickup_datetime=2026-03-17 20:42:22	Core Model: 288.2842	345.16	极高费用样本被低估，树模型对长尾目标回归偏向均值	对高费用样本分层训练或引入目标分位分层权重
3	1593	pickup_datetime=2026-03-05 22:23:46	LightGBM baseline: 63.4215	32.83	夜间样本被高估，可能受同时间段长距离样本影响	增加距离/时长交互、异常速度和短途夜间行程分层特征

5. 风险状态与后续计划

5.1 当前风险状态

风险	当前状态	应对方案
超参数未充分调优	Core Model 已通过调参降至 1.989580，但 XGBoost 仍弱于预期	后续继续开展 XGBoost 调参，并复核 LightGBM 在全量数据上的泛化表现
跨时间泛化风险	当前主要是单批次数据结果	后续使用跨周/跨月切分验证概念漂移

5.2. 终期冲刺详细排期（第 13 周 - 第 16 周）

阶段	主要任务	责任人	预期产物
第 13 周	完成 baseline 结果复核，补充公平训练设置	赵会洋、徐文彬	更新后的 baseline 对比表
第 14 周	进行 LightGBM/XGBoost 调参和特征重要性分析	赵会洋、崔琛浩	调参结果、特征重要性图
第 15 周	与核心模型/治理策略做 A/B 对比	徐文彬、崔琛浩	治理收益实验表、失败案例复盘
第 16 周	整理最终报告、PPT 和答辩材料	全员	最终报告、展示材料

6. AI 工具辅助使用记录

使用场景	AI 工具	具体辅助环节	人工审查与纠错说明
baseline 代码整理	Codex	拆分 Kaggle baseline 脚本，生成 <code>src/baseline</code> 下四类模型入口	逐个运行脚本并检查输出列、行数、缺失值和负预测
新版数据适配	Codex	将目标列改为 <code>base_passenger_fare</code> ，适配 <code>data/processed/fhvhv_tripdata_2026-03_prediction_format/</code> 结构	人工检查 <code>train.csv</code> 、 <code>test.csv</code> 、 <code>sample_submission.csv</code> 字段
评估脚本编写	Codex	编写 <code>evaluate_rmse.py</code> ，实现 RMSE 计算和排名输出	发现参考文件缺失值后修正为跳过无效行
报告整理	Codex	按中期模板补充 <code>baseline</code> 运行说明和结果分析	保留原有数据审计与治理内容，并人工核对指标数字