

数据挖掘课程项目 - 中期进展报告模板

本阶段重点考核：数据预处理与审计的落地情况、基线模型的跑通与评测、核心算法的开发进度以及后续关键里程碑的规划。请各小组在 第 13 周 提交本报告。

提交要求：

- 一份格式规范的 **PDF 中期进展报告**（建议控制在 5-8 页以内，重点突出，附带必要的定量实验图表）。
- 持续更新的 **代码仓库链接**（将检查代码提交历史、模块划分与运行说明）。

0. 项目基本信息

- 项目名称：** [请填写你的项目名称，如：基于 GraphRAG 的医学文献抗幻觉问答系统]
- 项目链接：** [请填写公开的代码仓库 URL]
- 小组成员与分工：**

姓名	学号	组内角色	开题以来的核心贡献	中期之后的分工规划
张三 (组长)	2026xxxx	算法开发	完成基线模型搭建与核心图检索模块实现	调优进阶模型，撰写最终报告
李四	2026xxxx	数据工程	负责医学文献清洗、实体关系提取与图谱构建	配合消融实验，丰富测试集
王五	2026xxxx	评测与实验	设计对比评测框架，完成首批实验结果统计	运行消融实验，绘制定量分析图表

1. 项目概述与当前状态

1.1. 中期里程碑达成情况

对比开题时制定的里程碑，目前项目处于什么阶段？（如：按计划进行 / 进度提前 / 进度滞后，并说明原因）。

- 计划目标：[如：在第11周跑通基线模型并完成数据图谱化]
- 实际达成：[如：已成功跑通 baseline 并完成 80% 数据清洗，图谱构建因实体对齐问题延迟了 3 天，但目前已解决]

1.2. 代码仓库状态审计

- 提交统计（必填，可通过 `git log --oneline | wc -l` 获取）：
 - 总 commit 数：[如 47 次]，开题后新增 commit 数：[如 32 次]
 - 活跃贡献人数：[如 3/3 人均有提交]（GitHub Insights 截图可附在附录）
- 分支与协作方式：[例：使用 3 个 Feature Branch（`feature/preprocess`、`feature/graph-build`、`feature/evaluate`），通过 PR 合并，共完成 8 次 PR review]
- 当前仓库目录结构（运行 `tree -L 2` 并粘贴实际输出，不可使用示例结构替代）：

```
# 请在此处粘贴你的仓库实际目录结构，并在右侧注释说明各模块的功能
├── README.md                # 运行说明与环境配置（含一键复现命令）
├── data/
│   ├── raw/                # 原始数据（或提供下载脚本
data/download.sh)
│   └── processed/          # 清洗后的中间数据
├── src/
│   ├── preprocess.py       # [说明：实现了哪些清洗步骤]
│   ├── baseline.py         # [说明：基线方法及评测入口]
│   ├── core_model.py       # [说明：进阶算法的核心逻辑]
│   └── evaluate.py         # [说明：评测指标计算逻辑]
├── notebooks/
└── requirements.txt
```

2. 数据工程与审计落地


2.1. 原始数据审计反馈

必填：请至少列出 **2** 条经代码验证的数据问题。如开题预测的某项挑战未发生，也请在最后一行明确注明原因。

数据问题	量化规模	解决方案（精确到文件/函数）	处理后效果
噪声标签	15.3% 样本标签存在冲突	Snorkel LabelModel 多源融合，见 <code>src/preprocess.py</code> L42-89	标签冲突率降至 2.1%，Precision +4.7%
实体长尾分布	63% 的实体出现次数 < 3	频次过滤 + 实体消歧，见 <code>notebooks/eda.ipynb</code> Cell 12	图谱节点数 12 万压缩至 3.8 万，查询平均跳数 -1.2
[请填写，不得留空]			

2.2. 数据流与预处理管道

必填：使用 Mermaid 流程图展示数据从原始状态到送入模型的完整流水线，每个节点须标注对应的脚本文件名或函数名（不接受纯文字替代）。



3. 基线模型与核心算法实现

3.1. 基线模型运行情况说明

必填：中期阶段基线模型必须已可完整运行并输出评测结果。

- **所选基线方法：**[例如：Vector-based RAG, BGE-M3 向量检索 + Qwen3.5-9B]
- **运行环境：**[例如：单张 RTX 3090 24G, Python 3.11, 推理耗时约1.2s/query]
- **一键复现命令（必填，评审会实际执行验证）：**

```
# 示例，请替换为你的实际命令
python src/baseline.py --data data/processed/test.jsonl --output
results/baseline.json
```

- **关键输出截图或日志片段：**[在此粘贴运行成功的终端输出关键行，或附图于附录]

3.2. 核心进阶算法开发进度

介绍你们针对开题问题设计的进阶算法或创新模块。

- **核心模块设计：**请用系统架构图（Mermaid）或文字，阐述进阶方法的设计原理（如：在 GraphRAG 中引入层次化社群检索 Community Summary）
- **开发进度核查表（必填，逐项如实勾选）：**

模块	对应文件	状态	备注
数据预处理管道	src/preprocess.py	完成 / 进行中 / 未开始	
基线模型	src/baseline.py	完成 / 进行中 / 未开始	
核心进阶算法	src/core_model.py	完成 / 进行中 / 未开始	
评测框架	src/evaluate.py	完成 / 进行中 / 未开始	
单元测试 / 集成测试	tests/	完成 / 进行中 / 未开始	

4. 中期实验结果与阶段性分析

4.1. 评估指标与测试集构建

- 评测数据集规模: [例如: 人工标注了 50 个复杂的多跳推理问答对作为 Benchmark 测试集]
- 核心评测指标 (Metrics): [如: 准确率 Accuracy、幻觉率 Hallucination Rate (基于 RAGAS 评估框架)、检索召回率 Recall@K]

4.2. 定量对比实验结果

请给出基线模型与当前进阶模型（即使是初代版本）的定量对比表格。

模型方法 (Method)	检索召回率 (Recall@5)	答案忠实度 (Faithfulness)	答案相关性 (Answer Relevance)	平均推理耗时 (Latency)
Baseline (Vector RAG)	72.4%	0.61	0.74	1.2s
Proposed (GraphRAG - Midterm Ver.)	88.6% (+16.2%)	0.84 (+0.23)	0.81 (+0.07)	3.5s (-2.3s)

4.3. 实验结果初步诊断与分析

必填：至少列出 2 个具体的失败案例。

#	输入 (Query 片段)	模型输出	正确答案	失败原因	改进方向
1	糖尿病与高血压的共病机制?	答案遗漏了胰岛素抗性路径	包含胰岛素抗性 + RAS 轴	相关实体在图谱中被孤立节点过滤掉	放宽频次过滤阈值, 或引入语义相似度补充稀疏实体
2	[请填写真实失败案例]				

- **总体优缺点小结**（2-4 句话）：[例如：多跳推理召回率显著提升，但推理延迟从 1.2s 升至 3.5s，下一步需优化图索引并引入并行查询]

5. 后续风险评估与冲刺排期

5.1. 风险清单动态调整

开题报告中提到的风险是否发生？是否出现了新的非技术/技术风险？

- **风险 1 状态评估**：[例如：开题提到的算力不足风险未发生，我们成功申请到了实验室的 A100 资源]
- **新增风险与应对预案**：[例如：实体提取的 API 调用费用超出预算。预案：切换为开源的本地部署 Qwen-2-7B-Instruct 提取实体，并设计 Few-shot Prompt 保持准确率]

5.2. 终期冲刺详细排期（第 13 周 - 第 16 周）

请给出精确到周的后续工作计划，确保项目能够按时、高质量地交付。

周次	核心任务目标	责任人	预期交付物 / 验收标准
第13周	解决中期暴露的 Latency 问题，优化图查询性能，跑通消融实验	张三、王五	图检索模块优化版代码、消融实验初步数据
第14周	进行大规模测试，收集消融实验与对比实验的完整数据，完成图表绘制	王五	实验结果可视化图表、详细的指标分析报告
第15周	整理代码仓库，撰写最终项目报告（规范学术论文格式），录制 Demo 视频	全员	GitHub 规范化 Release、演示视频、论文初稿
第16周	制作答辩 PPT，进行组内试讲，准备最终的项目答辩与成果展示	全员	最终答辩 PPT、系统演示 Demo

6. AI 工具辅助使用记录

按照课程规范，请如实填写。若完全未使用 AI 工具，在表格中注明“未使用”即可。

使用场景	AI 工具名称	具体辅助环节（精确到文件/功能）	团队审查与纠错说明
代码编写	DeepSeek	辅助编写 <code>src/preprocess.py</code> 中的正则匹配逻辑	逐行 Review，修复了空值处理的 Bug
报告撰写	豆包	润色系统架构部分的文字描述	组长人工核对，删除空泛词汇，确保与代码一致
算法思路	Claude 3.5	咨询图检索延迟优化的并行方案	方案经组内讨论后独立实现，非直接复制
[其他/未使用]			

中期自查清单 (Self-Check List)（提交前逐项确认）：

代码仓库

- ☐ GitHub 仓库已设为公开，且近两周内有真实的 commit 记录？
- ☐ 仓库 README.md 包含环境配置说明和一键复现命令，他人可独立运行？
- ☐ 所有组员至少有 1 次 commit？

数据与实验

- ☐ 数据审计表已填写，每条问题都给出了量化规模（百分比/数量）？
- ☐ 基线模型已完整跑通，报告中有实际的终端输出或截图为证？
- ☐ 进阶模型与基线已进行定量对比（有数字，不只是文字描述）？
- ☐ 误差分析部分包含至少 2 个具体的失败案例？

报告完整性

- ☐ 所有成员的分工和开题后的具体贡献都明确写入了成员分工表？
- ☐ 后续冲刺排期精确到周，责任人明确，且与当前进度匹配？

☐ AI 工具使用情况已如实填写（未使用也须注明）？