纽约市出租车行程数据挖掘——基于Data-Centric方法的费用预测与运营规律分析

成员

- 徐文彬(1120221397)
- 赵会洋(1120221594)
- 崔琛浩(1120221572)

1. Problem Definition（问题定义）

1.1 研究背景与问题

纽约市出租车与豪华轿车委员会（TLC）公开了数十亿条出租车行程记录，涵盖黄色出租车（Medallion Taxi）和网约车（FHV）等多种类型。这些数据是典型的真实世界大规模传感器数据，具有高噪声、多缺失、逻辑不一致等特征，是Data-Centric AI研究的理想场景。

本项目的核心研究问题包括：

- (1) 影响出租车费用的关键因素有哪些（距离、时间、乘客数、时段、地理区域等）？
- (2) 如何系统性地清洗和处理原始数据中普遍存在的缺失值、异常值和逻辑不一致问题，建立可复用的数据质量提升流水线？
- (3) 能否基于行程特征构建高精度的车费预测模型，为乘客提供可靠费用参考？
- (4) 哪些行程的费用显著偏离预期？这种偏离是由于数据错误、特殊事件（如拥堵、绕路），还是支付类型（如现金无小费）导致的？

任务形式化定义：

设原始行程样本空间为

$$\mathcal{D} = \{(x_i, y_i, t_i)\}_{i=1}^{N}, \tag{2}$$

其中：

- $x_i \in \mathbb{R}^p \times \mathcal{C}$ 表示第 i 条行程的多模态特征（连续特征如距离、时长、经纬度；离散特征如支付方式、时段类别）。
- $y_i \in \mathbb{R}_{\geq 0}$ 表示观测到的实际总费用（或目标费用字段）。
- t_i 表示时间戳，用于刻画时序分布与潜在漂移。

定义数据质量增强算子 $Q(\cdot)$，将原始数据映射到清洗后数据：

$$\widetilde{\mathcal{D}} = Q(\mathcal{D}). \tag{3}$$

学习目标为在训练集上求解预测函数

$$f_\theta : x \mapsto \hat{y}, \quad \theta^* = \arg\min_\theta \sum_{(x_i,y_i)\in\tilde{\mathcal{D}}_{train}} \ell(f_\theta(x_i), y_i), \tag{5}$$

其中 ℓ 为回归损失（如 MAE 或 MSE）。

最终输出包括：

- 费用预测输出：对任一新行程特征 x_{new}，输出预测费用 $\hat{y}_{new} = f_{\theta^*}(x_{new})$。
- 数据干预增益输出：

$$\Delta_{metric} = Metric(\mathcal{M}_{clean}) - Metric(\mathcal{M}_{raw}), \tag{6}$$

用于量化 Data-Centric 干预（清洗与一致性修复）相较原始数据在性能上的边际提升。

1.2 研究价值

- 业务价值：帮助出租车运营公司优化车辆调度策略（如高峰时段运力投放），为乘客提供行程费用的预估参考，减少因费用争议导致的投诉。同时可为城市交通管理部门提供出租车出行时空规律，辅助城市公共交通规划决策。
- 技术价值：本数据集是典型的真实世界脏数据，包含缺失值、异常值、逻辑矛盾（如费用与距离不匹配）、重复记录等多类数据质量问题。项目聚焦Data-Centric视角，探索数据质量提升对模型性能的边际收益，大规模数据（亿级记录）的处理对数据处理效率和内存管理提出了技术挑战。

2. Data Sourcing & Initial Audit（数据获取与初步审查）

2.1 数据来源

- 核心数据：纽约市TLC公开的黄色出租车行程记录数据（TLC Trip Record Data）。数据字段包括：上车时间（pickup_datetime）、下车时间（dropoff_datetime）、乘客数（passenger_count）、行程距离（trip_distance）、上车经纬度（pickup_longitude/pickup_latitude）、下车经纬度（dropoff_longitude/dropoff_latitude）、支付类型（payment_type）、费用金额（fare_amount）、小费（tip_amount）、总费用（total_amount）等。数据以CSV格式按月发布，累计数据量超过10亿条行程记录。
- 辅助数据：纽约市行政区划地图数据（用于地理可视化分析）、节假日日历数据（用于分析节假日出行规律）、天气数据（温度、降水量——用于分析天气对出行的影响）。
- 数据获取方案：数据免费公开于纽约市TLC官方网站（**https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page**）。直接从TLC官网批量下载。

数据规模与特征维度：

- 数据量级：全量黄色出租车历史数据累计超过 10^9 条记录；本项目阶段性实验优先使用按月切片与分块加载，单月常见规模约为 $10^6 \sim 10^7$ 条记录。
- 原始特征维度：核心结构化字段约 15-20 维（时间、空间、费用、支付、乘客等）。
- 建模特征维度：在时间与地理特征展开后，特征维度通常扩展至约 30-60 维（视编码策略与是否引入外部天气/节假日特征而变动）。
- 标签定义：监督学习主标签为 `total_amount`（或按实验设置替换为 `fare_amount`）。

2.2 数据初步审查

基于文件 `yellow_tripdata_2026-01.parquet` 的分块审查（row-group 级扫描）得到如下量化审查结果：

- 样本规模：共 3,724,889 条记录、20 个字段。
- 缺失值审查（**Top 5**）：`passenger_count`、`RatecodeID`、`store_and_fwd_flag`、`congestion_surcharge`、`Airport_fee` 的缺失率均为 29.2105%，显示缺失集中且可能与业务场景/采集流程相关。
- 异常值审查：
  - `trip_distance<=0` 占 3.3756%，`trip_distance>100` 占 0.0043%；
  - `fare_amount<=0` 占 1.1153%，`fare_amount>500` 占 0.0016%；
  - `total_amount<=0` 占 1.0851%，`total_amount>1000` 占 0.0001%；
  - `passenger_count<=0` 占 0.5608%。
- 时间逻辑一致性：负时长记录为 1 条（0.0000%），说明上下车时间字段整体一致性较好。
- 类别不平衡审查（**payment_type**）：类别 1 占 60.3977%，类别 0 占 29.2105%，类别 2 占 8.4309%，类别 4 占 1.5141%，类别 3 占 0.4468%；最大类占比 60.3977%，存在明显分布倾斜。
- 重复记录审查（关键字段组合估计）：重复约 2 条，占 0.0001%，完全重复风险较低。
- 分布波动线索：按日平均 `total_amount` 最小 26.1173、最大 43.0583、均值 29.5398，变异系数 $CV = 0.1044$，表明月内存在中等水平时序波动。
- 地理越界审查限制：该文件未包含经纬度字段，无法执行“坐标超出纽约范围”的越界比例统计。

结论：当前数据的主要痛点为“缺失值集中 + 距离/费用异常值 + 类别不平衡”；时间字段逻辑整体可靠，重复记录比例极低。关于 Concept Drift 的跨期结论需结合多月或跨年数据进一步验证。

3. Preliminary Methodology（初步方法）

3.1 探索性分析

数据概览（数据量、字段类型、缺失值统计）、费用分布分析（按整体和分时段）、行程距离分布、乘客数分布、支付方式占比、出行时段规律（按小时/星期/月份统计）、上车地点热力图可视化。分析结果将用于指导特征工程和模型设计。

3.2 核心技术

数据清洗与预处理：

- 缺失值处理：对关键字段（如经纬度）的缺失采用删除策略，对次要字段可采用均值/中位数填充。
- 异常值过滤：基于统计规则（如IQR方法、百分位数截断）和业务规则（如费用与距离的逻辑约束）进行过滤。
- 逻辑一致性校验：建立费用-距离的合理区间约束（距离 × 单位价格下限 ≤ 费用 ≤ 距离 × 单位价格上限 + 固定阈值），对违反规则的记录标记或剔除。
- 重复数据去重、数据类型标准化。

特征工程：

- 时间特征：提取星期几、小时、是否为工作日/节假日、高峰/平峰时段、是否夜间。
- 地理特征：从经纬度构造距离曼哈顿中心的欧氏距离、上车点所在行政区划、上下车点间直线距离。
- 支付方式编码。

预测建模：

- 基线模型：线性回归（作为可解释性基线）。
- 非线性模型：决策树/随机森林（捕捉非线性关系）、XGBoost（工业级梯度提升模型，作为主模型）。
- 模型可解释性：SHAP特征重要性分析，用于解释关键影响因素。

3.3 可选方法

- 聚类分析：对上下车地点进行K-Means聚类，识别热门出行区域。
- 深度学习：多层感知机（MLP）用于非线性预测，作为与传统方法的对比。
- 神经网络模型可基于PyTorch框架实现。

3.4 工具与框架

- 数据处理：Pandas、NumPy（内存优化：分块读取chunking、Dask）
- 可视化：Matplotlib、Seaborn、Folium（地理热力图）
- 建模：Scikit-learn、XGBoost、PyTorch
- 版本管理：Git + GitHub

4. Experiment Design & Metrics（实验设计与评估指标）

4.1 实验设计

- 数据划分：按时间顺序划分训练集/验证集/测试集（如按月份，前80%为训练集，后20%为测试集），避免随机划分导致的时间泄露。
- 对比实验：对比不同模型（线性回归 vs 随机森林 vs XGBoost vs MLP）在相同特征集上的预测性能。
- 消融实验：逐步添加特征组（基础特征 → +时间特征 → +地理特征），评估各组特征对模型性能的边际贡献。
- 数据质量影响实验：对比原始数据与清洗后数据上的模型性能差异，量化数据清洗对预测精度的提升，体现Data-Centric方法的价值。

4.2 评估指标

技术指标：

- 回归指标：RMSE（均方根误差）、MAE（平均绝对误差）、R^2（决定系数）
- 模型鲁棒性：在不同月份/年份数据上的性能稳定性（评估Concept Drift下的泛化能力）

业务指标：

- 费用预测误差控制在合理范围内（目标：MAE不超过车费的10-15%），使预测结果可为乘客提供具有实际参考价值的费用估算。
- 异常检测的查准率：标记为"异常费用"的行程中，经人工验证确认为异常的比例。

5. Risk Assessment & Timeline（风险评估与时间规划）

5.1 风险评估

风险	影响	概率	应对策略
数据量大（亿级记录），本地处理内存溢出	高	高	采用月度抽样进行原型开发；使用分块读取（chunking）或Dask分布式计算框架
原始数据质量问题严重（10-20%异常记录）	中	高	建立系统性数据质量评估流程，分类制定处理策略，完整记录清洗前后统计对比
费用预测受多因素非线性影响，简单模型效果有限	中	中	采用XGBoost等集成模型捕捉非线性关系，通过SHAP分析识别关键特征
费用与距离存在非对称异常逻辑	中	中	建立逻辑一致性校验规则，对违规记录单独标记并选择性剔除
Concept Drift导致模型跨时间段泛化能力不足	中	中	按时间段分层验证，必要时引入时间特征或分时间段建模

5.2 时间规划

阶段	时间	主要任务
数据准备与初始审计	第1-2周	数据下载、初步查看、数据质量审计报告、环境搭建
探索性分析与方法设计	第3-4周	EDA分析、可视化、确定清洗策略与建模方案
数据清洗与特征工程	第5-7周	清洗流水线实现、特征工程、数据质量前后对比
模型实现与调优	第8-10周	基线模型→XGBoost→可选深度学习，超参数调优
实验评估与消融分析	第11-13周	模型对比、消融实验、特征重要性分析、过拟合检验
成果整理与展示	第14-16周	报告撰写、PPT制作、代码整理、GitHub发布

5.3 AI使用声明

本项目在开发过程中使用了 AI 工具：Codex、Gemini，用于代码生成、调试与文档撰写辅助。所有 AI 生成内容均经团队人工审查与验证，确保正确性与可复现性。

6. 成员分工

成员	主要职责
徐文彬(1120221397)	数据获取与环境搭建、数据质量审计（Data Audit）、模型评估与对比分析、特征工程
赵会洋(1120221594)	数据清洗流水线设计与实现、特征工程、模型构建与超参数调优
崔琛浩(1120221572)	探索性数据分析与可视化、模型评估与对比实验、报告撰写与PPT制作

7. 交付物

- 项目**Proposal**（本文档，PDF格式，3-5页）
- **GitHub**仓库：https://github.com/C-CH621/datamining-taxi-2026-ChiikaDD
- 最终报告：详细分析报告（含数据质量审计、方法描述、实验结果、结论）
- 展示**PPT**：项目答辩用演示文稿